


물류 유통량 예측 분석 프로젝트

머신러닝 | GPT API 활용



Contents

Part 1. 데이터 분석

- I. 분석개요
- II. 데이터 개요
- III. 데이터 정제 및 전처리
- IV. 데이터 탐색적 분석 (EDA)
- V. Feature Engineering
- VI. 하이퍼파라미터 튜닝
- VII. 최종 모델 확인

Part 2. GPT 에이전트

- I. GPT 에이전트 활용
- II. 실행 화면
 - 분석 목적
 - 모델 성능 비교 및 결과 해석
- III. 기대 효과 및 한계점

>>>>> Part 1. 데이터 분석


1. 분석개요

물류 산업은 고객 수요와 서비스 품질에 따라 빠르게 변화하며, 효율적인 데이터 분석은 경쟁력 확보의 핵심 요소가 되었음.

유통량 데이터를 분석하여 패턴을 이해하고, 미래를 예측함으로써 운영 효율성을 극대화해야 늘어나는 물류 시장에서 선도기업이 될 것으로 예측.

① 늘어나는 택배 물동량

Parcel Volume in 2020 and 2023




- 2023년 우리나라 연간 택배물량은 51억 5천만 건으로 2020년(33억 7천만 건)보다 **52.9% 증가**
- **1인당 연간 이용자수 100.4건** 도달

(출처: 국가물류통합정보센터)

② 택배사 간 경쟁 가속화

Market Share of Major Parcel Companies in 2022



- 2022년 주요 택배사 간 시장 점유율을 나타내며, **CJ대한통운이 45%**로 가장 큰 비중을 차지
- 쿠팡, 롯데글로벌로지스, 한진택배가 각각 12%, 14%, 13%의 점유율

(출처: 로티스(LoTIS) 글로벌 물류기술 통합정보시스템)

③ 물류 유통량 예측 중요성 심화



- 쿠팡과 같은 기업들이 **자체 배송 서비스를 확대**함에 따라 전통적인 택배사와의 경쟁이 더욱 심화
- 이러한 환경에서 시장 점유율을 유지하기 위해서는 **정확한 유통량 예측이 필수**

》 인프라 투자 최적화, 비용 절감, 서비스 품질 향상

2. 데이터 개요

학습에 사용할 데이터(Train.csv)는 총 31,684개, 예측에 사용할 데이터(Test.csv)는 총 7,920개로 구성돼 있으며, 머신러닝을 통해 운송장 건수를 예측하는 것이 본 프로젝트의 목표임

train.csv

송하인_격자공간고유번호	수하인_격자공간고유번호	물품_카테고리	운송장_건수
5011000595017300	2871000192069300	음반	3
4148000690043300	5011000264024400	문화컨텐츠	3
5011000078068400	1120000007005400	농산물	3
4127100048006400	5011000587019400	기타식품	7
5011000078068400	2823700010076300	농산물	3
5013000778073200	4159000114016400	농산물	6

test.csv

송하인_격자공간고유번호	수하인_격자공간고유번호	물품_카테고리
4167000577042200	5011000435014100	선케어
1156000009012200	5011000172034400	구강위생용품
4122000363057300	5011000361097300	캠핑
5011000436041400	2826000084036400	아웃도어가구
4150000241065200	5011000169044300	분유/이유식/아기간식
5011000627031200	4713000116016300	커튼/블라인드
2826000127090100	5013000471090400	침구단품

주요 변수

- ① 송하인_격자공간고유번호 (int)
- ② 수하인_격자공간고유번호 (int)
- ③ 물품_카테고리 (string)
- ④ 운송장_건수 (int)

**train.csv 데이터를 통해
test.csv의 운송장_건수를 예측**

데이터 출처: Dacon ‘물류 유통량 예측 경진대회’
<https://dacon.io/competitions/official/235867/codeshare>

3. 데이터 정제 및 전처리 – ① 결측치 및 이상치 확인

학습에 사용할 데이터(Train.csv)에서 결측치는 발견되지 않았으며, 사분위수 범위 검증을 통해 이상치 검증을 시행함

결측치 확인

컬럼명	결측치
Index	0
송하인_격자공간고유번호	0
수하인_격자공간고유번호	0
물품_카테고리	0
운송장_건수	0

- 결측치는 모든 컬럼에서 0으로 관측됐으며, 데이터 정제가 이미 완료된 데이터로 보임

이상치 확인

IQR(Interquartile Range) 사분위수 범위

[이상치 탐지]


'index'에서 발견된 이상치 수: 0

'송하인_격자공간고유번호'에서 발견된 이상치 수: 7062

'수하인_격자공간고유번호'에서 발견된 이상치 수: 0

'운송장_건수'에서 발견된 이상치 수: 2475

이상치가 7062건 발견되었으나, '송하인_격자공간고유번호'는 공간을 나타내는 고유 번호로 보임



- 운송장_건수의 이상치를 확인했을 때, 400 건이 넘는 한 건을 제외하면 모두 정상 범위에 있는 것으로 확인
- 운송건이 많은 지역을 확인하는 것도 중요한 데이터라고 판단하여 해당 이상치를 유지하였음

3. 데이터 정제 및 전처리 – ② 데이터 변환 및 타겟 변수 확인

모델 학습 성능과 안정성을 확보하기 위해 범주형 데이터를 숫자로 변환하고, 타겟 변수의 불균형한 분포를 개선함

데이터 변환 (범주형 변수 인코딩)

물품_카테고리

선케어

구강위생용품

캠핑

아웃도어가구

분유/이유식/아기간식

커튼/블라인드

침구단품



train.csv의
물품_카테고리 데이터
타입이 string이기
때문에 변환이 필요함

원핫 인코딩 (One-Hot Encoding)은
범주형 데이터를 숫자로 변환하는 기법
중 하나로, 카테고리 변수(string)를 이진
벡터로 표현함



	가구	생활용품	전자제품
0	0	0	1
1	1	0	0
2	0	1	0
3	0	0	1
4	1	0	0

타겟 변수 확인 (로그변환)




- 대부분의 데이터가 0~10 사이에 분포함
- 대다수의 송하인/수하인은 상대적으로 적은 물량을 송신하며, 특정 소수의 송하인만 대규모의 물량을 처리하는 패턴을 확인함

>> 모델 학습과 일반화를 위해 로그 변환을 실행함.

4. 데이터 탐색적 분석 (EDA) - ① 변수 간 관계 분석

변수 간 상관관계를 분석하여 변수의 독립성과 관련성을 확인하고, 예측 모델에 적합한 주요 변수 선정의 방향성을 확인함



약한 상관관계

- 송하인_격자공간고유번호와 수하인_격자공간고유번호 간의 약한 음의 상관관계(-0.40)는 송하인과 수하인의 공간적 특성이 약간 반대되는 패턴을 가질 수 있음을 나타냄
- ▶ 이는 물류 흐름에서 송하인과 수하인이 서로 독립적일 가능성을 시사함

독립성

- 운송장_건수(및 운송장_건수_log)는 공간 고유 번호와 거의 독립적인 변수로 보임
- ▶ 공간적 요소와 운송량 간의 상관관계가 뚜렷하지 않음을 시사함


히트맵에서는 전반적으로 상관계수가 낮아, 변수 간의 독립성이 비교적 높음을 알 수 있으며, 이는 **모델링 시 개별 변수들이 독립적으로 작용할 가능성을 의미함**

>> 주요 변수 간 상관관계가 약하므로, 모델링 시 비선형 모델(랜덤 포레스트, XGBoost)을 사용해 변수 간의 관계를 학습해야 함

4. 데이터 탐색적 분석 (EDA) - ② 물품 카테고리별 운송 건수 및 평균 분석

물품 카테고리별 운송 건수를 분석하여 특정 카테고리가 전체 물류 흐름에 얼마나 기여하는지 확인하고, 데이터 분포 및 이상 패턴을 파악함


물품_카테고리별 운송 빈도수



- 가장 빈도가 **높은 물품 카테고리(농산물)**가 약 20,000건으로, 다른 카테고리에 비해 월등히 많음
- 농산물을 제외한 나머지 카테고리는 빈도가 상대적으로 낮으며, 긴 꼬리 형태로 분포함

▶ 물류 흐름에서 **농산물**이 주도적인 역할을 하고 있음

물품_카테고리별 평균 운송장 건수



- 특정 카테고리(농산물)에서 평균 운송장 건수가 매우 높은 값을 보임
- 대부분의 카테고리는 평균 운송장 건수가 5~15 사이에서 분포하고 있으며, 일부 카테고리가 평균적으로 더 많은 운송장 건수를 기록하고 있음

▶ 평균 운송장 건수에서는 **비교적 데이터 균형성**을 보여주고 있음


>> 모델링 시 물품 카테고리가 운송량에 얼마나 기여하는지 분석하는 것이 중요하다고 판단하여 '카테고리별 평균 운송장 건수'를 새로운 피처(Feature)로 추가함.

4. 데이터 탐색적 분석 (EDA) - ③ 격자공간고유번호

격자공간 고유번호와 운송장 건수 간의 관계성을 파악한 후 격자공간에 대한 전처리 과정을 진행함

앞 5자리는 시군구별 코드를 의미하기 때문에, 앞 5자리와 뒷 자리 숫자를 컬럼으로 나누어 격자공간고유번호 스케일을 축소함

격자공간고유번호 및 운송장 건수 간 분포도



- 송하인_격자공간고유번호와 운송장_건수 간에는 뚜렷한 상관관계가 관찰되지 않음
- 이는 기존의 격자 공간 번호가 운송장 건수를 예측하는데 유용하지 않을 수 있음을 시사함
- ▶ 격자공간 고유번호에 대한 추가적인 데이터 분석이 필요함

국토도시_격자공간50미터 기준 데이터 처리

지역경제 분석/활용/유통을 위한 세분화/표준화한 데이터(50미터격자)

No	격자공간고유번호	격자공간명	시군구코드	시군구명	격자공간사이즈
1	1111000001001100	다사5158	11110	종로구	50
2	1111000001001200	다사5158	11110	종로구	50
3	1111000001001300	다사5158	11110	종로구	50

- 송하인_격자공간고유번호와 수하인_격자공간고유번호에 사용된 데이터는 국토도시 격자공간 50미터 기준 데이터를 기반으로 수집된 것을 확인함
- 본 데이터를 기반으로 하여 격자공간 고유번호의 앞 다섯자리가 시군구코드를 의미함을 확인하였으므로, 앞 5자리(시군구코드)와 뒷자리(고유번호)를 파생변수로 생성하였음

송하인_격자공간고유번호	송하인_시군구코드	송하인_고유번호	수하인_격자공간고유번호	수하인_시군구코드	수하인_고유번호
5011000595017300	50110	00595017300	2871000192069300	28710	00192069300
4148000690043300	41480	00690043300	5011000264024400	50110	00264024400
5011000078068400	50110	00078068400	1120000007005400	11200	000007005400
4127100048006400	41271	00048006400	5011000587019400	50110	00587019400

≫ 시군구코드 및 고유번호 피처를 추가적으로 생성함

4. 데이터 탐색적 분석 (EDA) - ④ 시군구코드별 평균 운송장 건수

시군구코드를 기준으로 하여 운송장 건수를 파악한 결과 특정 시군구에 매우 집중돼 있음을 확인함

송하인 및 수하인 상위 10개 시군구코드 운송량

송하인 기준 상위 10개 시군구코드 운송량



송하인_시군구코드	운송장_건수
50110	60,067
50130	46,515
41480	6,470
41410	2,256
41500	1,992
41590	1,826
41461	1,748
41173	1,745
41360	1,514
41570	1,419

수하인 기준 상위 10개 시군구코드 운송량

수하인_시군구코드	운송장_건수
50110	38,246
50130	10,858
41590	2,188
11680	1,815
11710	1,530
11650	1,320
41273	1,268
11500	1,217
41360	1,162
28200	1,123

- 송하인 기준으로 가장 많은 운송장 건수를 기록한 시군구코드는 50110으로, 총 69,067건을 기록함
- 운송장 건수의 분포는 상위 시군구코드에서 매우 집중되어 있으며, 이는 주요 발송 지역이 몇몇 시군구코드에 편중되어있으며, 주요 수신 지역도 특정 시군구코드에 집중되어 있음

송하인 및 수하인 시군구코드별 평균 운송장 건수



5. Feature Engineering – ① 파생 변수 생성

EDA를 바탕으로 얻은 인사이트를 바탕으로 유의미할 것 같은 변수를 생성함.

```
[42]: # 송하인/수하인 시군구코드별 평균 운송장 건수 계산
train['송하인_시군구코드'] = train['송하인_격자공간고유번호'].astype(str).str[:5]
train['수하인_시군구코드'] = train['수하인_격자공간고유번호'].astype(str).str[:5]

송하인_평균_운송장 = train.groupby('송하인_시군구코드')['운송장_건수'].mean().rename('송하인_시군구코드별_평균_운송장_건수')
수하인_평균_운송장 = train.groupby('수하인_시군구코드')['운송장_건수'].mean().rename('수하인_시군구코드별_평균_운송장_건수')

train = train.merge(송하인_평균_운송장, on='송하인_시군구코드', how='left')
train = train.merge(수하인_평균_운송장, on='수하인_시군구코드', how='left')

[43]: # 송하인/수하인 운송량 (총합) 계산
송하인_운송량 = train.groupby('송하인_시군구코드')['운송장_건수'].sum().rename('송하인_운송량')
수하인_운송량 = train.groupby('수하인_시군구코드')['운송장_건수'].sum().rename('수하인_운송량')

train = train.merge(송하인_운송량, on='송하인_시군구코드', how='left')
train = train.merge(수하인_운송량, on='수하인_시군구코드', how='left')

[44]: # 카테고리별 운송장 건수 카운트 계산
카테고리_운송장_건수_카운트 = train.groupby('물품_카테고리')['운송장_건수'].count().rename('카테고리_운송장_건수_카운트')
train = train.merge(카테고리_운송장_건수_카운트, on='물품_카테고리', how='left')

[45]: # 시군구코드 추출
train['송하인_시군구코드'] = train['송하인_격자공간고유번호'].astype(str).str[:5]
train['수하인_시군구코드'] = train['수하인_격자공간고유번호'].astype(str).str[:5]
# 조합 변수 생성
train['송수하인_시군구_조합'] = train['송하인_시군구코드'] + '_' + train['수하인_시군구코드']

[46]: # 단일거래/다중거래 여부
# 송수하인 조합 기준 거래 횟수 계산
transaction_counts = train.groupby('송수하인_시군구_조합')['운송장_건수'].count().rename('송수하인_거래횟수')
train = train.merge(transaction_counts, on='송수하인_시군구_조합', how='left')
# 거래 여부 플래그 생성
train['거래유형'] = train['송수하인_거래횟수'].apply(lambda x: '다중거래' if x > 20 else '단일거래')
```




- 송하인/수하인시군구코드별 평균 운송장 건수
- 송하인/수하인운송량 총합
- 카테고리별 운송장 건수 총합
- 송하인/수하인시군구코드
- 송수하인 시군구 조합 = 송하인 시군구코드 + '-' + 수하인 시군구코드
- 송수하인 조합 기준 거래 횟수

송수하인_거래횟수의 평균값: 34.21598272138229
 송수하인_거래횟수의 최소값: 1
 송수하인_거래횟수의 중간값: 15.0

다중거래 기준을 20회라고 한 이유

5. Feature Engineering – ② Feature Importance

Feature Importance에서 보고자 하는 것은 어떤 변수(칼럼 또는 피쳐)가 모델 성능에 가장 크게 영향을 미치는 건지 확인하는 것이고, 피쳐 중요도를 세 가지 모델에서 실행해보고 RMSE 점수를 산정함.



모델 종류	RMSE 점수	랭킹
LightGBM	0.3668	1
XGBoost	0.3701	2
랜덤포레스트	0.3889	3

LightGBM 피쳐 중요도가 골고루 분포 되어 있음, 모델 성능을 결정하는데 모든 변수가 고르게 작동한다는 것을 의미함

▶ 오버 피팅을 방지하기 위해 모델 성능에 특정한 피쳐만 영향을 미치는게 아니라 골고르게 영향을 미치는 모델을 선택

>> LightGBM 모델 사용 결정

6. 하이퍼파라미터 튜닝

LightGBM의 하이퍼파라미터를 최적화하여 모델의 예측 성능을 극대화하고, 검증 데이터를 통해 최적 조합을 확인함

(1) 데이터 분할

```
X_train, X_valid, y_train, y_valid = train_test_split(X, y, test_size=0.2, random_state=42)
```

- 데이터를 학습(train)과 검증(validation) 세트로 분리하여 모델 성능 평가를 준비

(2) 하이퍼파라미터 그리드 설정

```
param_grid = {
    'n_estimators': [100, 300, 500],
    'learning_rate': [0.01, 0.05, 0.1],
    'max_depth': [5, 7, 10],
    'num_leaves': [20, 31, 40],
    'min_child_samples': [10, 20, 30]
}
```

- n_estimators: 결정 트리의 개수
- learning_rate: 학습률
- max_depth: 각 트리의 최대 깊이
- num_leaves: 하나의 트리에서 가질 수 있는 리프 노드(leaf node)의 최대 개수
- min_child_samples: 리프 노드에서 필요한 최소 데이터 수

- 탐색할 하이퍼파라미터의 값 범위를 설정하여 최적의 조합을 찾음

(3) LightGBM 모델과 그리드 서치 설정 후 실행

```
lgb_model = lgb.LGBMRegressor(random_state=42)
grid_search = GridSearchCV(estimator=lgb_model, param_grid=param_grid, cv=3, scoring='neg_root_mean_squared_error', verbose=1)
```

- 그리드 서치를 통해 최적의 하이퍼파라미터를 탐색하고, 교차 검증(CV)으로 성능 평가

(4) 최적 하이퍼파라미터와 점수 확인


```
최적 하이퍼파라미터: {'learning_rate': 0.01, 'max_depth': 5, 'min_child_samples': 10, 'n_estimators': 300, 'num_leaves': 20}
최적 RMSE: 0.36983660789140393
```

- 최적 하이퍼파라미터와 해당 조합에서의 최적 RMSE를 도출하여 모델 성능 확인

7. 최종 모델 확인

최적의 하이퍼파라미터를 적용하여 예측 성능을 개선한 최종 모델을 정의했으며, 잔차 분석을 통해 전반적으로 양호한 예측 성능을 확인함

(5) 잔차분석



- X축(Actual Values): 실제 값
- Y축(Residuals): 실제 값과 예측 값의 차이(잔차)
- 잔차가 빨간 점선(잔차 = 0) 주변에 밀집되어 있는 경우, 모델이 데이터를 잘 예측하고 있다는 것을 의미함

(6) 최적 하이퍼파라미터를 기반으로 최종 모델 정의

```
final_lgb_model = LGBMRegressor(
    learning_rate=0.01,
    max_depth=5,
    min_child_samples=10,
    n_estimators=300,
    num_leaves=20,
    random_state=42
)
```



index	운송장_건수
0	3.085925315
1	3.085925315
2	7.262834363
3	5.417757353
4	3.613169043
5	3.096075432
6	4.084695098
7	3.085925315
8	3.085925315
9	9.036969723

(7) 최종 결과 확인

- RSME: 0.3629

>>>>> Part 2. GPT 에이전트

1. GPT 에이전트 활용 – 머신러닝 데이터 분석

머신러닝 작업에 GPT 에이전트를 활용하면 데이터 전처리, 모델 선택, 하이퍼파라미터 튜닝, 결과 해석까지 전 과정에서 실질적인 도움을 받을 수 있음.

기능/작업	기능 설명	예시 질문
(1) 분석 목적 확인	데이터 분석 전에 어떤 기대효과와 목적을 가지고 분석을 진행할 지 설명	“이 분석으로 기대할 수 있는 효과는 무엇인가요?”
(2) 자동화된 데이터 이해 및 설명	데이터 탐색 지원, 전처리 제안	“이 컬럼의 분포를 분석해줘”, “주요 통계값을 요약해줘”
(3) 머신러닝 모델 선택	데이터의 특성과 문제(분류, 회귀 등)에 따라 적합한 모델을 추천	“이 데이터셋에 적합한 모델은 무엇인가요?”
(4) 모델 평가와 결과 해석	여러 모델의 평가 결과(RMSE, MAE, R ² 등)를 바탕으로 어떤 모델이 적합한지 논리적인 분석을 제안	“이 결과에서 가장 적합한 모델은 무엇인가요?”
(5) RAG 추가하여 전문 도메인 지식기반의 조언	특정 산업(예: 물류, 금융, 의료)에 특화된 조언을 제공할 수 있으며, 도메인 지식을 활용한 맞춤형 분석과 의사결정 지원이 가능	“운송량 예측 모델에서 고려해야 할 주요 KPI는 무엇인가요?”

>> (1) 분석 목적 확인, (4) 모델 평가와 결과 해석 기능을 가지고 있는 GPT 에이전트 구현

2. 구현 화면

GPT API를 연결하여 파이썬 Streamlit으로 에이전트 구현

<https://drive.google.com/file/d/14Cma5EM474tco1XGJQbabbpZAQRTcSZ4Y/view?usp=sharing>

▶ 첫번째 페이지 - '물류 유통량 예측 분석'

페이지를 선택하세요

물류 유통량 예측 분석

물류 유통량 예측 분석



분석 개요 🚚

이 프로젝트는 물류 유통량 예측을 목적으로 진행됩니다. 주어진 데이터(`train.csv`)를 기반으로 운송 장_건수를 예측하여, 물류 시스템의 효율성을 높이는 데 기여할 수 있습니다.

분석 목적 🎯

- 물류 데이터의 패턴을 파악하고, 데이터를 기반으로 미래의 물류 수요를 예측.
- 예측된 결과를 통해 물류 운영 비용 절감 및 리소스 최적화 달성.

질문하기:

택배회사의 물류 유통량 예측 분석의 기대효과는?

▶ 두번째 페이지 - '모델 성능 비교 및 결과 해석'


페이지를 선택하세요

머신러닝 모델 비교 및 분석

모델 학습 및 RSME 계산

모델 성능 비교

모델별 RSME 비교



Model	RSME
Random Forest	~6.8
XGBoost	~6.8
LightGBM	~5.8

질문하기 (GPT):

어떤 모델이 가장 적합한가요?

질문 보내기

>> 머신러닝 데이터 분석 목적을 확인하고, 머신러닝 모델별 성능 점수를 평가하고 결과를 해석하는데 도움을 받을 수 있음

3. 기대 효과와 한계점

GPT 에이전트를 활용하면 머신러닝 모델의 데이터 분석, 성능 평가, 결과 해석에 있어 시간 절약, 결과 신뢰성 향상, 비용 절감, 의사결정 품질 개선 등 다양한 기대효과를 얻을 수 있음

기대효과

비용 절감 | 인력 최적화

모델 성능 비교와 같은 반복 작업을 GPT가 효율적으로 지원해주면서 전체 개발 비용과 시간을 절감할 수 있음.

모델별 점수를 GPT가 자동으로 분석하므로, 현업에 있는 분석가들이 모델 개발과 최적화에 집중할 수 있음.

한계점

도메인 지식의 한계

GPT는 도메인 지식이 부족할 경우 일반적인 답변만을 제공할 수 있음. 이를 보완하기 위해 RAG와 같은 외부 데이터 검색 기능을 통합할 필요가 있음.

≫ GPT 에이전트는 단순히 도구로 끝나는 것이 아니라, 머신러닝 모델 개발과 데이터 분석 과정에서 핵심적인 지원 역할을 수행 할 수 있음.

THANK YOU.